TP 2 – SY02
Probabilités
Corrigé

Les questions/sections marquées par un sont des questions qui sont prévues pour être traitées en autonomie en dehors de la séance de TP.

1 Étude de peintres

Roger de Piles est un peintre et critique d'art français du 18ème siècle. Pour évaluer un peintre, de Piles a considéré quatre critères : composition, dessin, couleur, expression. Chacune de ces caractéristiques est notée sur 20. Plusieurs écoles artistiques ont été étudiés par de Piles : (A) renaissance, (B) maniériste, (C) italienne du 17ème siècle, (D) vénitienne, (E) lombarde, (F) 16ème siècle, (G) 17ème siècle, (H) française. Dans le logiciel `R`, on peut accéder aux notes de 54 peintres évalués par de Piles en chargeant tout d'abord la bibliothèque `MASS` :

```
library(MASS)
```

Les données sont alors accessibles à travers le `data.frame painters` :

```
head(painters)
```

```
             Composition Drawing Colour Expression School
Da Udine              10       8     16          3      A
Da Vinci              15      16      4         14      A
Del Piombo             8      13     16          7      A
Del Sarto             12      16      9          8      A
Fr. Penni              0      15      8          0      A
Guilio Romano         15      16      4         14      A
```

(1) En utilisant des histogrammes, visualiser la distribution des notes pour chaque critère.

```
par(mfrow = c(2, 2))                # Permet d'afficher plusieurs graphiques dans une seule fenêtre
hist(painters$Composition, main = "Composition", xlab = "Note")
hist(painters$Drawing, main = "Dessin", xlab = "Note")
hist(painters$Colour, main = "Couleur", xlab = "Note")
hist(painters$Expression, main = "Expression", xlab = "Note")
```

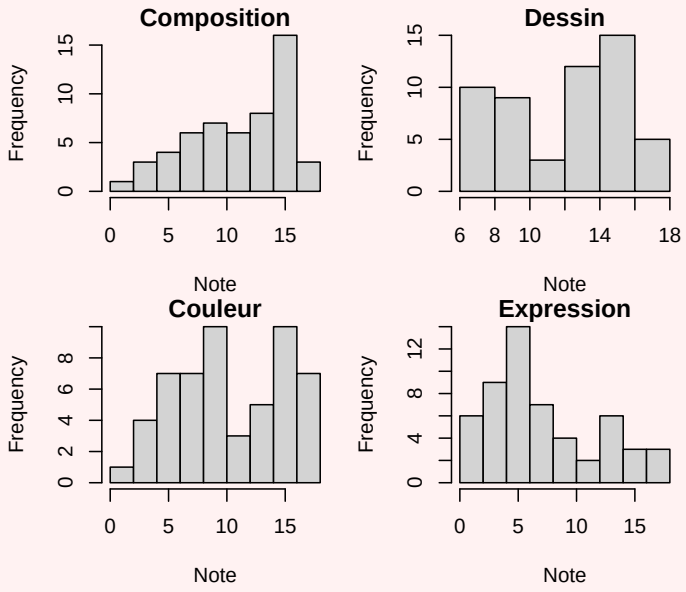

(2) Calculer dans un vecteur `moyenne` la moyenne des quatre notes de chaque peintre.

```
(moyenne <- (painters[, 1] + painters[, 2] + painters[, 3] + painters[, 4])/4)
 [1]  9.25 12.25 11.00 11.25  5.75 12.25  9.25 11.00  7.50 16.25  9.75 11.00
[13]  9.25 11.50 11.50 10.00 11.25 12.00  7.00 10.00  8.00 13.75  7.75  6.00
[25]  9.75  8.25 10.25  6.75 11.00 12.25 12.75 11.00 11.00  7.00 13.25 14.50
[37] 10.50 10.50 14.50  9.00 12.00  7.75  6.00 10.25 10.00 11.75 12.50 16.25
[49] 11.50 13.75  7.50 14.00 12.25 13.25
```

(3) Calculer la moyenne empirique, les variances et écarts types empiriques corrigés et non-corrigés de ce vecteur `moyenne` en n'utilisant que la fonction `sum`.

```
n <- length(moyenne)
(x_ <- sum(moyenne)/n)                                  # moyenne empirique
[1] 10.65741
(s2 <- sum((moyenne - x_)^2)/n)                         # variance empirique
[1] 6.171982
(s <- sqrt(s2))                                         # écart-type empirique
[1] 2.484347
(s2_ <- sum((moyenne - x_)^2)/(n - 1))                  # variance empirique corrigée
[1] 6.288435
(s_ <- sqrt(s2_))                                       # écart-type empirique corrigé
[1] 2.507675
```

(4) Retrouver les valeurs précédentes à l'aide des fonctions `mean`, `var` et `sd`.

```
mean(moyenne)                                           # moyenne empirique
[1] 10.65741
var(moyenne)                                            # variance empirique corrigée
```

```
[1] 6.288435
sd(moyenne)                                          # écart-type empirique corrigé
[1] 2.507675
var(moyenne) * ((n - 1)/n)                           # variance empirique
[1] 6.171982
sd(moyenne) * sqrt((n - 1)/n)                        # écart-type empirique
[1] 2.484347
```

⑤ Tracer l'histogramme du vecteur `moyenne` et commenter le résultat.

```
hist(moyenne)
```

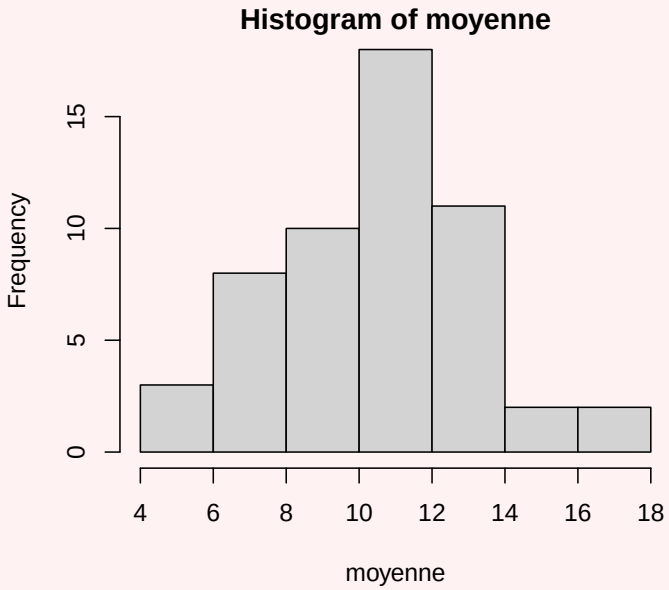

Alors que la distribution des notes pour chaque critère n'est pas gaussienne, la moyenne de ces notes semble plus en accord avec une loi normale.

2 Calcul de probabilités

Plusieurs lois de probabilités sont incluses par défaut dans `R`. Parmi les plus communes, on peut citer :

- la loi uniforme : `unif` ;
- la loi de Poisson : `pois` ;
- la loi exponentielle : `exp` ;
- la loi binomiale : `binom` ;
- la loi normale : `norm` ;
- la loi de Student : `t` ;
- la loi du χ^2 : `chisq` ;
- la loi de Fisher : `f`.

Pour chacune de ces lois, il est possible d'accéder à la fonction de densité en ajoutant le préfixe `d`, à la fonction de répartition avec `p`, aux fractiles avec `q` et à un générateur de nombre

aléatoire en utilisant le préfixe `r`. À titre d'exemple, étudions la loi uniforme sur l'intervalle $[2, 5]$ notée $\mathcal{U}([2, 5])$. La valeur de sa fonction de densité $f(x)$ en un point x peut être calculée à l'aide de la fonction `dunif`.

```
dunif(1, min = 2, max = 5)
[1] 0
dunif(2, min = 2, max = 5)
[1] 0.3333333
dunif(4, min = 2, max = 5)
[1] 0.3333333
dunif(6, min = 2, max = 5)
[1] 0
```

Les arguments `min` et `max` permettent de spécifier l'intervalle $[2, 5]$. Ces paramètres sont propres à la loi uniforme. Pour chaque loi disponible dans `R`, tous les paramètres associés sont listés et expliqués dans l'aide.

Soit $X \sim \mathcal{U}([2, 5])$, la probabilité $\mathbb{P}(X \leq 4) = F_X(4)$ peut être obtenue avec la commande suivante :

```
punif(4, min = 2, max = 5)
[1] 0.6666667
```

Le fractile d'ordre α est retourné par la fonction `qunif`.

```
qunif(0.25, min = 2, max = 5)  # fractile d'ordre 0.25, premier quartile
[1] 2.75
```

Enfin, la commande `runif` permet d'obtenir la réalisation d'une variable aléatoire suivant une loi uniforme.

```
runif(1, min = 2, max = 5)
[1] 4.673318
runif(1, min = 2, max = 5)
[1] 3.208925
runif(10, min = 2, max = 5)        # permet d'obtenir la réalisation d'un
↪  échantillon de taille 10
 [1] 3.684039 4.515070 2.333422 2.805263 3.038829 2.867576 3.878826
 ↪  3.032835
 [9] 3.781072 3.469543
```

(6) À l'aide des fonctions introduites précédemment, calculer avec `R` les probabilités des événements suivants :

1. une variable normale centrée-réduite est supérieure à 3 ;
2. une variable normale d'espérance 35 et d'écart-type 6 est inférieure à 42 ;
3. une variable normale d'espérance 35 et d'écart-type 6 est comprise entre 40 et 50 ;
4. obtenir $n-1$ faces sur n lancers d'une pièce de monnaie équilibrée, avec $n = 5,\ 10,\ 30$;
5. obtenir strictement plus de 14 faces sur 20 lancers d'une pièce de monnaie équilibrée ;
6. obtenir entre 10 et 15 faces sur 20 lancers d'une pièce de monnaie équilibrée.

```
# Question 1
1 - pnorm(3)
[1] 0.001349898
pnorm(3, lower.tail = FALSE)                          # une autre matière d'obtenir le même résultat
[1] 0.001349898
# Question 2
pnorm(42, mean = 35, sd = 6)
[1] 0.8783275
pnorm((42 - 35)/6)                      # même résultat en passant par la loi normale centrée réduite
[1] 0.8783275
# Question 3
pnorm(50, mean = 35, sd = 6) - pnorm(40, mean = 35, sd = 6)
[1] 0.1961187
# Question 4
dbinom(4, 5, 0.5)
[1] 0.15625
dbinom(9, 10, 0.5)
[1] 0.009765625
dbinom(29, 30, 0.5)
[1] 2.793968e-08
# Question 5
1 - pbinom(14, 20, 0.5)
[1] 0.02069473
sum(dbinom(15:20, 20, 0.5))                                                    # autre solution
[1] 0.02069473
# Question 6
pbinom(15, 20, 0.5) - pbinom(9, 20, 0.5)
[1] 0.5821896
sum(dbinom(10:15, 20, 0.5))                                                  # deuxième solution
[1] 0.5821896
```

(7) Calculer avec R les fractiles d'ordre $\alpha = 0.05,\ 0.1,\ 0.9$ pour les lois suivantes et les retrouver dans les tables statistiques du cours :

1. loi normale centrée réduite ;
2. loi du χ^2 à 10 degrés de liberté ;
3. loi de Student à 5 degrés de liberté ;
4. loi de Fisher à 2 et 5 degrés de liberté.

```
alpha <- c(0.05, 0.1, 0.9)
# Question 1
qnorm(alpha)
[1] -1.644854 -1.281552  1.281552
# Question 2
qchisq(alpha, 10)
[1]  3.940299  4.865182 15.987179
# Question 3
qt(alpha, 5)
[1] -2.015048 -1.475884  1.475884
# Question 4
qf(alpha, 2, 5)
[1] 0.05182311 0.10761220 3.77971608
```

3 Implémentation d'une loi de probabilité

On souhaite maintenant ajouter à R la loi de probabilité (densité, fonction de répartition, fonction quantile et simulation de v.a.) du premier exercice du TD n° 2 définie par la densité

de probabilité suivante :

$$f(x) = \begin{cases} ax & \text{si } 0 \leq x \leq b \\ 0 & \text{sinon} \end{cases},$$

avec $b > 0$ et $a = 2/b^2$. On notera cette loi $\mathcal{L}(b)$.

Sous `R`, il est possible de définir des fonctions avec la commande `function`. Par exemple, on peut définir la fonction `carre` qui à tout nombre x associe son carré x^2 de la manière suivante :

```
carre <- function(x) {
  y <- x * x
  return(y)
}
```

La fonction `carre` peut maintenant être utilisée comme une fonction de `R`.

```
carre(2)
[1] 4
carre(9)
[1] 81
```

Il est également possible de créer une fonction prenant plusieurs arguments. On peut construire la fonction `puissance` qui à deux nombres a et b associent a^b de la façon suivante :

```
puissance <- function(a, b) {
  return(a^b)
}
```

On obtient ainsi :

```
puissance(2, 3)
[1] 8
puissance(16, 1/2)
[1] 4
```

On peut remarquer qu'il est également possible de passer des vecteurs comme arguments des fonctions `carre` et `puissance`.

```
carre(c(1, 3, 5))
[1]  1  9 25
puissance(2:5, 3)
[1]   8  27  64 125
```

(8) Écrire la fonction `dloi(x, b)` qui pour tout $x \in \mathbb{R}$ donne la valeur de la fonction de densité $f(x)$ de la loi $\mathcal{L}(b)$. On vérifiera que la fonction peut également prendre un vecteur en argument.

```r
dloi <- function(x, b) {
    a <- 2/b^2
    f <- a * x
    f[x < 0] <- 0
    f[x > b] <- 0
    return(f)
}
```

La fonction `dloi` prend bien un vecteur en argument et donne la densité en chaque élément du vecteur. L'usage d'une boucle `for` et d'une structure de contrôle `if` est possible quoique inefficace et verbeuse.

(9) On choisit $b = 3$, calculer la valeur de $f(x)$ pour $x = -1,\ 0,\ 1,\ 2,\ 3,\ 4,\ 5$.

```r
dloi(-1:5, 3)
[1] 0.0000000 0.0000000 0.2222222 0.4444444 0.6666667 0.0000000 0.0000000
```

Il est possible de visualiser facilement la fonction `dloi` avec la commande suivante :

```r
curve(dloi(x, 3), from = -5, to = 5)
```

où les arguments `from` et `to` correspondent aux bornes entre lesquelles tracer la courbe.

(10) Écrire la fonction `ploi(x, b)` qui donne la fonction de répartition F de la loi $\mathcal{L}(b)$.

La fonction de répartition est calculable directement à partir de la densité. On trouve

$$F(x) = \begin{cases} 0 & \text{si } x < 0 \\ \dfrac{x^2}{b^2} & \text{si } x \in [0; b] \\ 1 & \text{si } x > b, \end{cases}$$

d'où la fonction suivante.

```r
ploi <- function(x, b) {
    F <- x^2/b^2
    F[x < 0] <- 0
    F[x >= b] <- 1
    return(F)
}
```

(11) Tracer la fonction de répartition F entre -5 et 5 avec $b = 3$.

```r
curve(ploi(x, 3), from = -5, to = 5)
```

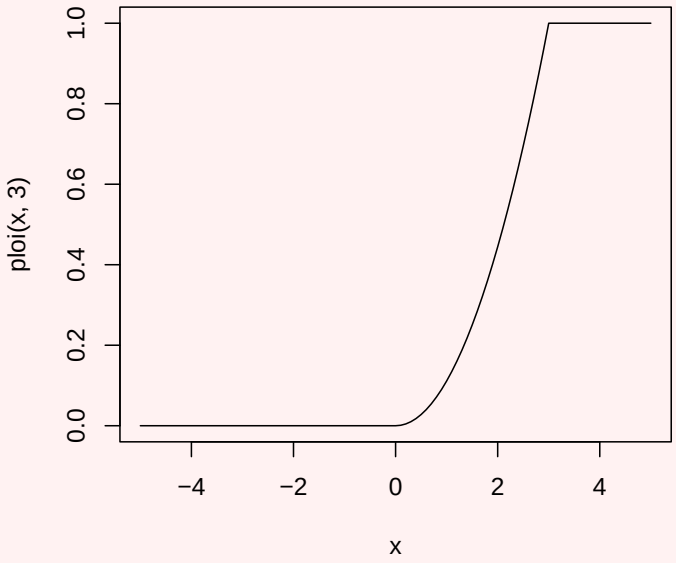

On observe bien la croissance de la fonction de répartition avec le morceau de parabole entre 0 et $b = 3$.

(12) Écrire la fonction `qloi(alpha, b)` qui renvoie les fractiles $f_\alpha = F^{-1}(\alpha)$ de la loi $\mathcal{L}(b)$. On admettra que $F^{-1}(0) = 0$ et $F^{-1}(1) = b$.

On a la propriété suivante :

$$\forall \alpha \in]0;1[, \quad F^{-1}(\alpha) = b\sqrt{\alpha}.$$

```
qloi <- function(alpha, b) {
    fa <- b * sqrt(alpha)
    fa[alpha == 0] <- 0
    fa[alpha == 1] <- b
    return(fa)
}
curve(qloi(x, 3), from = 0, to = 1)
```

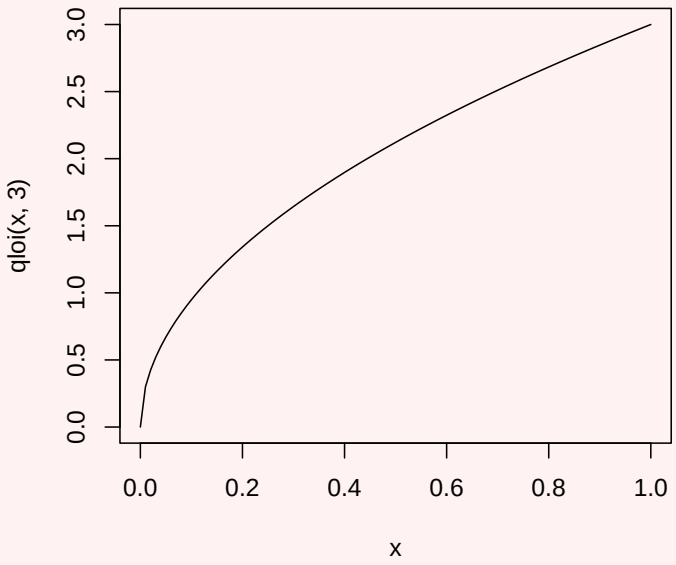

Soit $X \sim \mathcal{L}(b)$, on souhaite maintenant générer des réalisations de la variable aléatoire X.

(13) Utiliser le résultat du quatrième exercice du TD n° 2 pour écrire la fonction `rloi(n, b)` qui génère aléatoirement un échantillon de taille n suivant la loi $\mathcal{L}(b)$.

```
rloi <- function(n, b) {
    u <- runif(n)
    x <- qloi(u, b)
    return(x)
}
```

(14) Générer un échantillon de taille n suivant la loi $\mathcal{L}(b)$ et vérifier graphiquement que cette distribution empirique est proche de la loi $\mathcal{L}(b)$ quand n grandit. On prendra $b = 3$.

```
par(mfrow = c(2, 2))
for (n in c(10, 50, 100, 1000)) {
    hist(rloi(n, 3), breaks = round(1 + 10/3 * log10(n)), freq = FALSE, main = n, xlim = c(-1, 4))
    curve(dloi(x, 3), add = TRUE, col = "red")
}
```

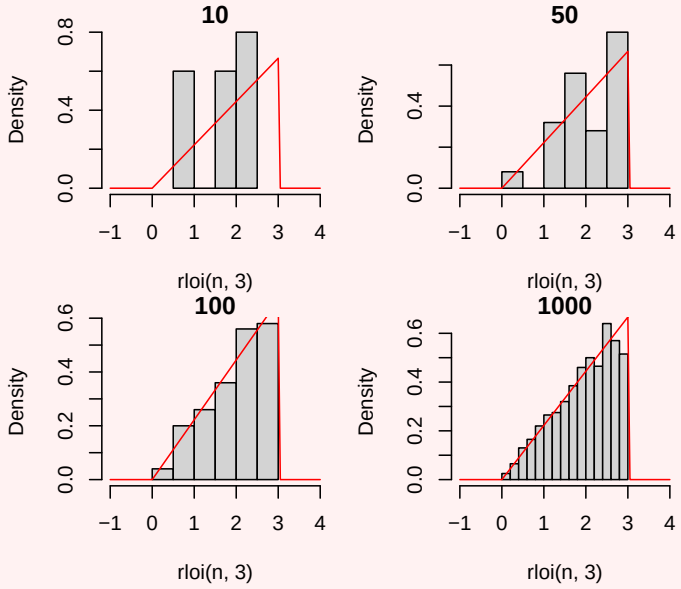

La distribution empirique des échantillons semble coïncider avec la densité f à mesure que n grandit.

4 Bonus

On peut remarquer que la fonction `puissance` n'est définie pour les réels a et b. En effet, si $a < 0$, alors la fonction `puissance` n'est pas définie pour $b \in]-1; 1[$. De même, si $a = 0$, alors la fonction `puissance` n'est pas définie pour $b < 0$.

```
puissance(-1, 1/2)
[1] NaN
```

```
puissance(0, -2)
[1] Inf
```

La fonction `stop` permet d'afficher un message d'erreur et d'arrêter l'exécution d'une fonction. On peut compléter la fonction puissance ainsi :

```
puissance <- function(a, b) {
    if (any(a < 0) & b > -1 & b < 1)
        stop("non définie pour a < 0 et -1 < b < 1")
    if (any(a == 0) & b < 0)
        stop("non définie pour a = 0 et b < 0")
    return(a^b)
}
```

```
puissance(-1, 1/2)
Error in puissance(-1, 1/2): non définie pour a < 0 et -1 < b < 1
puissance(0:2, -2)
Error in puissance(0:2, -2): non définie pour a = 0 et b < 0
```

(15) Corriger les fonctions `dloi`, `ploi`, `qloi` et `rloi` pour qu'elles affichent un message d'erreur lorsque leurs arguments sont mal définis.

```
dloi <- function(x, b) {
    if (b <= 0)
        stop("on doit avoir b > 0")
    a <- 2/b^2
    f <- a * x
    f[x < 0] <- 0
    f[x > b] <- 0
    return(f)
}
ploi <- function(x, b) {
    if (b <= 0)
        stop("on doit avoir b > 0")
    F <- x^2/b^2
    F[x < 0] <- 0
    F[x >= b] <- 1
    return(F)
}
qloi <- function(alpha, b) {
    if (b <= 0)
        stop("on doit avoir b > 0")
    if (any(alpha < 0) | any(alpha > 1))
        stop("on doit avoir 0 <= alpha <= 1")
    fa <- b * sqrt(alpha)
    fa[alpha == 0] <- 0
    fa[alpha == 1] <- b
    return(fa)
}
```

```r
rloi <- function(n, b) {
    if (b <= 0)
        stop("on doit avoir b > 0")
    if (!is.integer(n) | n < 1)
        stop("n doit être un entier strictement positif")
    u <- runif(n)
    x <- qloi(u, b)
    return(x)
}
```